

MVP: Engenharia de Dados

Autora: Amanda de Laia da Fonseca

Data: 14/12/2025

Matrícula: 4052025001101

Dataset: Drug Consumption (Quantified) -

<https://archive.ics.uci.edu/dataset/373/drug+consumption+quantified>

ÍNDICE

1. **OBJETIVO**
2. **DESENVOLVIMENTO**
 - a. Preparo de ambiente
 - b. Upload de dados
 - c. Etapa Bronze
 - d. Etapa Silver
 - i. Primeira tratativa - Rename de colunas (todas)
 - ii. Segunda tratativa - Drop de colunas que não serão usadas em nenhum momento
 - iii. Terceira tratativa - Tradução dos dados para linguagem de fácil compreensão
 - iv. Quarta tratativa - busca e, caso necessário, limpeza de valores NULL ou Unknown ou vazio
 - e. Etapa Gold
3. **ANÁLISES**
4. **CONCLUSÃO**
5. **QUALIDADE DOS DADOS**
6. **AUTO-AVALIAÇÃO**

1. OBJETIVO

O presente trabalho tem por objetivo criar uma base de dados no Databricks, adequar a estrutura e tratar os dados, a fim de analisar as questões propostas a seguir.

O Dataset utilizado contém dados que correlacionam usuários de diferentes tipos de drogas a diferentes tipos de personalidades (medidas pelo inventário psicológico NEO-FFI-R), além de variáveis essenciais como idade, nacionalidade e grau de escolaridade. Foi coletado desse repositório <https://archive.ics.uci.edu/dataset/373/drug+consumption+quantified> e possui licença CCA 4.0 International, estando livremente disponível para estudos.

Esse dataset já foi previamente utilizado por mim na disciplina de Machine Learning e, por isso, quis continuar a análise dele (dessa vez, de forma mais ampla). Por ser uma única tabela que já contém as informações que eu preciso e por precisar de diversas transformações como limpeza e mapeamentos categóricos, utilizarei o modelo de Data Lake. Uma vantagem futura dessa escolha é a possibilidade de importar outros tipos de dados, como informações clínicas e geográficas, em diferentes formatos para se gerar análises mais amplas e também aprofundadas.

Como se sabe, a política antidrogas é questão de saúde e segurança pública, sendo de grande importância para a sociedade o melhor entendimento de fatores que podem acabar levando uma pessoa a usar drogas e até mesmo uma predição de condições favoráveis ao uso. Dessa forma, o sistema público poderia interferir de alguma maneira antes que a pessoa se viciasse. Acesso à educação, à saúde, acompanhamento psicológico e condições mínimas de vida são algumas opções que o poder público deve oferecer à sociedade pois contribuiriam para o afastamento e a redução do uso de drogas.

Neste trabalho, não consideraremos os diferentes tipos de personalidades pois são dados que requerem certo conhecimento de Psicologia para que possam ser analisados e eu não possuo esse conhecimento. Além disso, por questões de tempo e objetividade, decidi pelo recorte de 3 das drogas mais consumidas no mundo: a Maconha, a Cocaína e a Anfetamina. Porém, mantive uma tabela tratada e com todas as drogas para possibilitar diferentes análises fora desse escopo proposto. Com isso, proponho as seguintes questões a serem respondidas:

- Qual o perfil dos maiores usuários dessas drogas? Idade, Gênero e Escolaridade seguem algum padrão nesses casos?
- Existe correlação entre consumo de Cannabis, Anfetaminas e Cocaína? (co-uso)
- Como o poder público poderia atuar para reduzir a quantidade de usuários?

2. DESENVOLVIMENTO

2.1. Preparo de ambiente

Inicialmente, prepararei o ambiente criando o catálogo "mvp" e os schemas abaixo:

- ★ staging: etapa em que os dados serão carregados na plataforma
- ★ bronze: etapa em que a tabela a ser trabalhada será criada e suas colunas catalogadas
- ★ silver: etapa em que os dados serão transformados (ETL) para uma melhor análise
- ★ gold: etapa em que a tabela final será criada e as análises serão executadas a fim de responder às questões propostas

03:49 PM (4)

```

%sql
DROP CATALOG IF EXISTS mvp CASCADE;
CREATE CATALOG mvp;
USE CATALOG mvp;
DROP SCHEMA IF EXISTS staging CASCADE;
CREATE SCHEMA staging;
DROP SCHEMA IF EXISTS bronze CASCADE;
CREATE SCHEMA bronze;
DROP SCHEMA IF EXISTS silver CASCADE;
CREATE SCHEMA silver;
DROP SCHEMA IF EXISTS gold CASCADE;
CREATE SCHEMA gold;

```

Hide performance (11) [View all in query history](#)

Statement	Started At	Duration	Rows read	Bytes read	Bytes written
> CREATE SCHEMA gold	Dec 07, 2025, 03:49 PM	275 ms	0	0 B	0 B
> DROP SCHEMA IF EXISTS gold CASCADE	Dec 07, 2025, 03:49 PM	126 ms	0	0 B	0 B
> CREATE SCHEMA silver	Dec 07, 2025, 03:49 PM	302 ms	0	0 B	0 B
> DROP SCHEMA IF EXISTS silver CASCADE	Dec 07, 2025, 03:49 PM	127 ms	0	0 B	0 B
> CREATE SCHEMA bronze	Dec 07, 2025, 03:49 PM	276 ms	0	0 B	0 B
> DROP SCHEMA IF EXISTS bronze CASCADE	Dec 07, 2025, 03:49 PM	129 ms	0	0 B	0 B
> CREATE SCHEMA staging	Dec 07, 2025, 03:49 PM	419 ms	0	0 B	0 B
> DROP SCHEMA IF EXISTS staging CASCADE	Dec 07, 2025, 03:49 PM	280 ms	0	0 B	0 B
> USE CATALOG mvp	Dec 07, 2025, 03:49 PM	118 ms	0	0 B	0 B
> CREATE CATALOG mvp	Dec 07, 2025, 03:49 PM	997 ms	0	0 B	0 B
> DROP CATALOG IF EXISTS mvp CASCADE	Dec 07, 2025, 03:49 PM	115 ms	0	0 B	0 B

OK

2.2. Upload de dados

Aqui, o volume "drug_consumption" será criado para receber os dados em formato .csv. Conforme dito anteriormente, será utilizada uma única tabela contendo os dados necessários para a análise proposta.

O upload do arquivo .csv será feito de forma manual via interface gráfica do Databricks.

Just now (2)

```

%sql
USE CATALOG mvp;
USE SCHEMA staging;
CREATE VOLUME drug_consumption

```

Hide performance (3) [View all in query history](#)

Statement	Started At	Duration	Rows read	Bytes read	Bytes written
> CREATE VOLUME drug_consumption	Dec 07, 2025, 04:14 PM	727 ms	0	0 B	0 B
> USE SCHEMA staging	Dec 07, 2025, 04:14 PM	154 ms	0	0 B	0 B
> USE CATALOG mvp	Dec 07, 2025, 04:14 PM	137 ms	0	0 B	0 B

OK

2.3. Etapa Bronze

Nesta etapa, a tabela base e todo o catálogo serão criados. Esta tabela utiliza a vírgula como separador, não possui cabeçalho e os dados não estão em um formato legível

(apenas números e códigos). Utilizando as informações disponíveis no site onde foi coletada, todos esses dados serão adaptados e transformados na etapa Silver.

Just now (1s)

7

```
spark.sql("USE CATALOG mvp")
spark.sql("USE SCHEMA bronze")
```

See performance (2)

DataFrame[]

Just now (5s)

8

```
df = spark.read.option("header", False).option("sep", ",").csv("dbfs:/Volumes/mvp/staging/drug_consumption/drug_consumption.csv")
df.write.format("delta").mode("overwrite").saveAsTable("drug_consumption")
display(df.limit(10))
```

Hide performance (2)

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
L3 > display(df.limit(10))	Dec 07, 2025, 04:49 PM	1/1 completed	1329 ms	10	319.49 KB	0 B
L2 > df.write.format("delta").mode("overwrite").saveAsTable("drug_consumption")	Dec 07, 2025, 04:49 PM	3/3 completed	4 s 246 ms	3.770	638.98 KB	31.01 KB

df: pyspark.sql.connect.dataframe.DataFrame = [C0: string, C1: string ... 30 more fields]

Table

	c0	c1	c2	c3	c4	c5	c6	c7	c8	c9	c10	c11	c12	c13	c14	c15	c16	c17	c18
1	1	49.788	48.246	-5.921	96.082	12.600	31.287	-57.545	-58.331	-91.699	-665	-21.712	-118.084	C15	C12	C10	C16	C18	C10
2	2	-7.854	-48.246	198.437	96.082	-31.685	67.825	193.886	143.533	76.096	-14.277	-71.126	-21.575	C15	C12	C10	C16	C14	C16
3	3	49.788	-48.246	-5.921	96.082	-31.685	-46.725	80.523	-84.732	-162.090	-101.450	-137.963	40.148	C16	C10	C10	C16	C13	C16
4	4	-95.197	48.246	116.365	96.082	-31.685	-14.882	-80.615	-1.928	59.042	58.489	-137.963	-118.084	C14	C10	C10	C13	C15	C12
5	5	49.788	48.246	198.437	96.082	-31.685	73.545	-163.340	-45.174	-30.172	130.612	-21.712	-21.575	C14	C11	C11	C10	C16	C13
6	6	258.171	48.246	-122.751	24.923	-31.685	-67.825	-30.033	-155.521	203.972	163.088	-137.963	-154.858	C12	C10	C10	C16	C10	C10
7	7	109.449	-48.246	116.365	-57.009	-31.685	-46.725	-109.207	-45.174	-30.172	93.949	-21.712	7.987	C16	C10	C10	C10	C16	C11
8	8	49.788	-48.246	-173.790	96.082	-31.685	-132.828	193.886	-84.732	-30.172	163.088	19.268	-52.593	C15	C10	C10	C16	C10	C10
9	9	49.788	48.246	-5.921	24.923	-31.685	62.967	257.309	-97.631	76.096	113.407	-137.963	-154.858	C14	C10	C10	C16	C10	C10
10	10	49.788	48.246	-5.921	24.923	-31.685	62.967	257.309	-97.631	76.096	113.407	-137.963	-154.858	C14	C10	C10	C16	C10	C10

10 rows | 5.03s runtime

Refreshed now

Os comentários a seguir foram copiados da fonte original, para garantir a confiabilidade das informações e dar o devido crédito aos criadores:

<https://archive.ics.uci.edu/dataset/373/drug+consumption+quantified>

As colunas c6 a c12 não terão seus possíveis valores "traduzidos", pois não serão utilizadas no presente trabalho e necessitam de um conhecimento prévio de Psicologia para entender e analisar esses valores.

05:01 PM (2s)

10

```
spark.sql("""
COMMENT ON TABLE mvp.bronze.drug_consumption IS
'Database contains records for 1885 respondents. For each respondent 12 attributes are known: Personality measurements which include NEO-FFI-R (neuroticism, extraversion, openness to experience, agreeableness, and conscientiousness), BIS-11 (impulsivity), and ImpSS (sensation seeking), level of education, age, gender, country of residence and ethnicity. All input attributes are originally categorical and are quantified. After quantification values of all input features can be considered as real-valued. In addition, participants were questioned concerning their use of 18 legal and illegal drugs (alcohol, amphetamines, mvy) nitrite, benzocaine, cannabis, chocolate, cocaine, caffeine, crack, ecstasy, heroin, ketamine, legal highs, LSD, methadone, mushrooms, nicotine and volatile substance abuse and one fictitious drug (Semeron) which was introduced to identify over-claimers. For each drug they have to select one of the answers: never used the drug, used it over a decade ago, or in the last decade, year, month, week, or day.
Database contains 18 classification problems. Each of independent label variables contains seven classes: "Never Used", "Used over a Decade Ago", "Used in Last Decade", "Used in Last Year", "Used in Last Month", "Used in Last Week", and "Used in Last Day".'
""")
```

Hide performance (1)

Statement	Started At	Duration	Rows read	Bytes read	Bytes written
L1 > spark.sql(""" COMMENT ON TABLE mvp.bronze.drug_consumption IS 'Database contains records for 1885 respondents. For each respondent 12 attributes are known: Personali...	Dec 07, 2025, 05:01 PM	1 s 446 ms	0	0 B	0 B

DataFrame[]

```
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c0 IS 'Number of record in original database. Cannot be related to participant. It can be used for reference only'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c1 IS 'Age of participant and has one of the values: -95.197: 18-24 / -7.854: 25-34 / 49.788: 35-44 / 109.449: 45-54 / 182.213: 55-64 / 259.171: 65+""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c2 IS 'Gender of participant: 48.246: Female / -48.246: Male""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c3 IS 'Level of education of participant and has one of the values: -243.591: Left school before 16 years / -173.790: Left school at 16 years / -143.719: Left school at 17 years / -122.731: Left school at 18 years / -61.113: Some college on university, no certificate on degree / -5.921: Professional certificate on diploma / 45.468: University degree / 116.365: Masters degree / 198.437: Doctorate degree""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c4 IS 'Country of current residence of participant and has one of the values: -9.765: Australia / 24.923: Canada / -46.841: New Zealand / -28.519: Other / 21.128: Republic of Ireland / 96.882: UK / -57.009: USA""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c5 IS 'Ethnicity of participant and has one of the values: -50.212: Asian / -110.702: Black / 190.725: Mixed-Black/Asian / 12.600: Mixed-White/Asian / -22.166: Mixed-White/Black / 11.460: Other / -31.655: White""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c6 IS 'Nscore is NEO-FFI-R Neuroticism.'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c7 IS 'Escore is NEO-FFI-R Extraversion.'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c8 IS 'Oscore is NEO-FFI-R Openness to experience.'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c9 IS 'Ascore is NEO-FFI-R Agreeableness.'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c10 IS 'Cscore is NEO-FFI-R Conscientiousness.'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c11 IS 'Impulsive is Impulsivity measured by BIS-11.'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c12 IS 'SS is sensation seeking measured by Ispss.'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c13 IS 'Class of alcohol consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c14 IS 'Class of amphetamines consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c15 IS 'Class of amyl nitrite consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c16 IS 'Class of benzodiazepine consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c17 IS 'Class of caffeine consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c18 IS 'Class of cannabis consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c19 IS 'Class of chocolate consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c20 IS 'Class of cocaine consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c21 IS 'Class of crack consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c22 IS 'Class of ecstasy consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c23 IS 'Class of heroin consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c24 IS 'Class of ketamine consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c25 IS 'Class of legal highs consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c26 IS 'Class of LSD consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c27 IS 'Class of methadone consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c28 IS 'Class of magic mushrooms consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c29 IS 'Class of nicotine consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c30 IS 'Class of fictitious drug Semoron consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c31 IS 'Class of volatile substance abuse consumption. It is output attribute with following distribution of classes: C0: Never Used / C1: Used over a Decade Ago / C2: Used in Last Decade / C3: Used in Last Year / C4: Used in Last Month / C5: Used in Last Week / C6: Used in Last Day'""")
```

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c31 IS 'Class of volatile substance abuse consumption. It is output attr...	Dec 07, 2025, 09:32 PM		1786 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c30 IS 'Class of fictitious drug Semoron consumption. It is output attr...	Dec 07, 2025, 09:32 PM		1824 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c29 IS 'Class of nicotine consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1843 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c28 IS 'Class of magic mushrooms consumption. It is output attribute wi...	Dec 07, 2025, 09:32 PM		1979 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c27 IS 'Class of methadone consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1892 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c26 IS 'Class of LSD consumption. It is output attribute with followin...	Dec 07, 2025, 09:32 PM		1730 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c25 IS 'Class of legal highs consumption. It is output attribute with f...	Dec 07, 2025, 09:32 PM		1879 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c24 IS 'Class of ketamine consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1904 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c23 IS 'Class of heroin consumption. It is output attribute with follow...	Dec 07, 2025, 09:32 PM		1894 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c22 IS 'Class of ecstasy consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1833 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c21 IS 'Class of crack consumption. It is output attribute with follow...	Dec 07, 2025, 09:32 PM		1640 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c20 IS 'Class of cocaine consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1874 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c19 IS 'Class of chocolate consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1619 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c18 IS 'Class of cannabis consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1676 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c17 IS 'Class of caffeine consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1821 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c16 IS 'Class of benzodiazepine consumption. It is output attribute wit...	Dec 07, 2025, 09:32 PM		1819 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c15 IS 'Class of amyl nitrite consumption. It is output attribute with...	Dec 07, 2025, 09:32 PM		1 s 456 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c14 IS 'Class of amphetamines consumption. It is output attribute with ...	Dec 07, 2025, 09:32 PM		1 s 177 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c13 IS 'Class of alcohol consumption. It is output attribute with foll...	Dec 07, 2025, 09:32 PM		1 s 235 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c12 IS 'SS is sensation seeking measured by Ispss.'""")	Dec 07, 2025, 09:32 PM		1 s 197 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c11 IS 'Impulsive is Impulsiveness measured by BIS-11.'""")	Dec 07, 2025, 09:32 PM		1 s 56 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c10 IS 'Cscore is NEO-FFI-R Conscientiousness.'""")	Dec 07, 2025, 09:32 PM		1889 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c9 IS 'Ascore is NEO-FFI-R Agreeableness.'""")	Dec 07, 2025, 09:32 PM		1 s 378 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c8 IS 'Oscore is NEO-FFI-R Openness to experience.'""")	Dec 07, 2025, 09:32 PM		1926 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c7 IS 'Escore is NEO-FFI-R Extraversion.'""")	Dec 07, 2025, 09:32 PM		1 s 173 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c6 IS 'Nscore is NEO-FFI-R Neuroticism.'""")	Dec 07, 2025, 09:32 PM		1 s 582 ms	3	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c5 IS 'Ethnicity of participant and has one of the values: -50.212: Asia...	Dec 07, 2025, 09:32 PM		1 s 281 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c4 IS 'Country of current residence of participant and has one of the va...	Dec 07, 2025, 09:32 PM		1 s 393 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c3 IS 'Gender of participant: 48.246: Female / -48.246: Male""")	Dec 07, 2025, 09:32 PM		1 s 257 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c1 IS 'Age of participant and has one of the values: -95.197: 18-24 / -7...	Dec 07, 2025, 09:32 PM		981 ms	0	0 B	0 B
spark.sql("""COMMENT ON COLUMN mvp.bronze.drug_consumption_c0 IS 'Number of record in original database. Cannot be related to parti...	Dec 07, 2025, 09:32 PM	8/8 completed	3 s 229 ms	3	0 B	0 B

DataFrame[]

2.4. Etapa Silver


Aqui serão feitas todas as transformações e adequações necessárias para o tratamento dos dados.

A primeira tratativa será a nomeação correta das colunas, já que o csv não tinha cabeçalho e o sistema nomeou por default todas elas.

A segunda tratativa será o filtro de colunas que não serão usadas nesse trabalho e que não terão seus valores traduzidos para linguagem "real". São as colunas que indicam diferentes tipos de personalidades medidas conforme o inventário psicológico NEO-FFI-R e que precisam de certo conhecimento de outras áreas para melhor entendimento.

A terceira tratativa será traduzir os números para string, com valores que façam sentido para análise humana.

A quarta tratativa será o filtro das colunas de interesse para esse trabalho, que serão utilizadas nas análises. Com isso, farei a busca por valores nulos e fora do padrão.



Statement	Started At	Duration	Rows read	Bytes read	Bytes written
12 > spark.sql("USE SCHEMA silver")	Dec 07, 2025, 08:02 PM	187 ms	0	0 B	0 B
11 > spark.sql("USE CATALOG mvp")	Dec 07, 2025, 08:02 PM	224 ms	0	0 B	0 B

2.4.1. Primeira tratativa - Rename de colunas (todas)

Utilizando o pyspark, criei uma função chamada "rename_columns" para facilitar o trabalho, já que são 31 colunas.

2 minutes ago (10)

14

Python

```

from pyspark.sql import DataFrame

#definindo a função rename para usar na sequência
def rename_columns(df: DataFrame, new_names: dict) -> DataFrame:
    for old_name, new_name in new_names.items():
        df = df.withColumnRenamed(old_name, new_name)
    return df

#usando a função para renomear as colunas
df = spark.table("mrp.bronze.drug_consumption")

renames = {
    "_c0": "ID",
    "_c1": "Age",
    "_c2": "Gender",
    "_c3": "Education",
    "_c4": "Country",
    "_c5": "Ethnicity",
    "_c6": "Nscore",
    "_c7": "Escore",
    "_c8": "Oscore",
    "_c9": "Ascore",
    "_c10": "Cscore",
    "_c11": "Impulsive",
    "_c12": "SS",
    "_c13": "Alcohol",
    "_c14": "Amphet",
    "_c15": "Amyl",
    "_c16": "Benzos",
    "_c17": "Caff",
    "_c18": "Cannabis",
    "_c19": "Choc",
    "_c20": "Coke",
    "_c21": "Crack",
    "_c22": "Ecstasy",
    "_c23": "Heroin",
    "_c24": "Ketamine",
    "_c25": "Legal",
    "_c26": "LSD",
    "_c27": "Methadone",
    "_c28": "Mushrooms",
    "_c29": "Nicotine",
    "_c30": "Semen",
    "_c31": "VSA"
}

df_renamed = rename_columns(df, renames)
df_renamed.write.mode("overwrite").saveAsTable("drug_consumption")

```

2 minutes ago (10)

15

Python

```

%sql
SELECT *
FROM drug_consumption
LIMIT 10

```

See performance (1)

Optimize

%sqldf: pyspark.sql.connect.dataframe.DataFrame = (ID: string, Age: string, 30 more fields)

Table

	ID	Age	Gender	Education	Country	Ethnicity	Nscore	Escore	Oscore	Ascore	Cscore	Impulsive	SS	Alcohol	Amphet	Amyl
1	49.788	48.246	-5.921	96.082	12.600	31.287	-57.545	-58.331	-91.699	-465	-21.712	-118.084	C15	C12	C10	
2	7.854	-48.246	198.437	96.082	-31.685	-47.825	193.886	143.533	76.096	-14.277	-71.126	-21.575	C15	C12	C12	
3	89.788	-48.246	-5.921	96.082	-31.685	-46.725	80.593	-84.732	-162.090	-101.450	-137.983	40.148	C16	C10	C10	
4	95.197	48.246	116.365	96.082	-31.685	-14.882	80.615	-1.928	59.042	58.489	-137.983	-118.084	C14	C10	C10	
5	49.788	48.246	198.437	96.082	-31.685	73.545	-162.340	-45.174	-30.172	130.612	-21.712	-21.575	C14	C11	C11	
6	259.171	48.246	-132.751	24.923	-31.685	-47.825	30.033	-155.531	203.872	163.088	137.983	-154.858	C12	C10	C10	
7	109.449	-48.246	116.365	-57.009	-31.685	-46.725	-109.207	-45.174	-30.172	93.949	-21.712	7.987	C16	C10	C10	
8	49.788	-48.246	-173.390	96.082	-31.685	-132.828	193.886	-84.732	-30.172	161.088	19.268	-52.593	C15	C10	C10	
9	49.788	48.246	-5.921	24.923	-31.685	62.367	257.309	-97.631	76.096	113.407	-137.983	-154.858	C14	C10	C10	
10	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...

10 rows | 3.02s runtime

Refreshed 1 minute ago

This result is stored as %sqldf and can be used in other Python and SQL cells.

2.4.2. Segunda tentativa - Drop de colunas que não serão usadas em nenhum momento

Aqui, removerei as colunas referentes aos índices de personalidade pois não serão utilizadas neste trabalho: Nscore, Escore, Oscore, Ascore, Cscore, Impulsive e SS.

```

from pyspark.sql.functions import split, explode, trim, lower

df = spark.table("mvp.silver.drug_consumption")

df_expanded = df.drop("Nscore", "Escore", "Oscore", "Ascore", "Cscore", "Impulsive", "SS")

df_expanded.write.mode("overwrite").option("overwriteSchema", "true").saveTable("drug_consumption")

#df_expanded.write.mode("overwrite").saveTable("drug_consumption") - esse comando removeu somente os dados e não as colunas. por isso, tive que fazer o overwrite do schema também.

```

Hide performance (1) View all in query history

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
17 > df_expanded.write.mode("overwrite").option("overwriteSchema", "true").saveTable("drug_consumption")	Dec 07, 2025, 08:22 PM	1/1 completed	3 s 126 ms	1,885	26.41 KB	26.41 KB

> df: pyspark.sql.connect.dataframe.DataFrame = (ID: string, Age: string ... 23 more fields)

> df_expanded: pyspark.sql.connect.dataframe.DataFrame = (ID: string, Age: string ... 23 more fields)

```

-- Just now (1s)
-- 19
-- Sql
SELECT *
FROM drug_consumption
LIMIT 10
-- See performance (1)
-- _sqldf: pyspark.sql.connect.dataframe.DataFrame = (ID: string, Age: string ... 23 more fields)

```

Table	ID	Age	Gender	Education	Country	Ethnicity	Alcohol	Amphet	Amyl	Benzos	Caff	Cannabis	Choc	Coke	Crack	Ecstasy
1	1	49.788	48.246	-5.921	96.082	12.600	C15	C12	C12	C16	C10	C15	C10	C10	C10	C10
2	2	-7.854	-48.246	198.437	96.082	-31.685	C15	C12	C10	C16	C14	C16	C13	C10	C14	C10
3	3	49.788	-48.246	-5.921	96.082	-31.685	C16	C10	C10	C10	C16	C13	C14	C10	C10	C10
4	4	-95.197	48.246	116.365	96.082	-31.685	C14	C10	C10	C13	C15	C12	C14	C12	C10	C10
5	5	49.788	48.246	198.437	96.082	-31.685	C14	C11	C11	C10	C16	C13	C16	C10	C10	C11
6	6	259.171	48.246	-122.751	24.923	-31.685	C12	C10	C10	C10	C16	C10	C14	C10	C10	C10
7	7	109.449	-48.246	116.365	-57.009	-31.685	C16	C10	C10	C10	C16	C11	C15	C10	C10	C10
8	8	49.788	-48.246	-173.790	96.082	-31.685	C15	C10	C10	C10	C10	C10	C14	C10	C10	C10
9	9	49.788	48.246	-5.921	24.923	-31.685	C14	C10	C10	C10	C16	C10	C16	C10	C10	C10
10	10	49.788	48.246	-5.921	24.923	-31.685	C14	C10	C10	C10	C16	C10	C16	C10	C10	C10

10 rows | 1.23s runtime Refreshed now

This result is stored as `_sqldf` and can be used in other Python and SQL cells.


```
from itertools import chain
from pyspark.sql.functions import create_map, lit, col, trim
from pyspark.sql import DataFrame

#definindo uma função para aplicar em cada uma das colunas de forma mais rápida

def apply_mapping(df: DataFrame, col_name: str, mapping_dict: dict, new_col_name: str = None) -> DataFrame:
    """
    Substitui valores da coluna `col_name` de acordo com mapping_dict.
    Compara sempre como string + trim.
    """
    mapping_expr = create_map([lit(x) for x in chain(*mapping_dict.items())])
    target_col = new_col_name or col_name
    return df.withColumn(target_col, mapping_expr[trim(col(col_name).cast("string"))])

#mapeamento de valores
age_map = {
    "-95.197": "18-24",
    "-7.854": "25-34",
    "49.788": "35-44",
    "109.449": "45-54",
    "182.213": "55-64",
    "259.171": "65+"
}

gender_map = {
    "48.246": "Female",
    "-48.246": "Male"
}

education_map = {
    "-243.591": "Left school before 16",
    "-173.790": "Left school at 16",
    "-143.719": "Left school at 17",
    "-122.751": "Left school at 18",
    "-61.113": "Some college/university, no degree",
    "-5.921": "Professional certificate/diploma",
    "45.468": "University degree",
    "116.365": "Masters degree",
    "198.437": "Doctorate degree"
}

country_map = {
    "-9.765": "Australia",
    "24.923": "Canada",
    "-46.841": "New Zealand",
    "-28.519": "Other",
    "21.128": "Republic of Ireland",
    "96.082": "UK",
    "-57.009": "USA"
}

ethnicity_map = {
    "-50.212": "Asian",
    "-110.702": "Black",
    "190.725": "Mixed-Black/Asian",
    "12.600": "Mixed-White/Asian",
    "-22.166": "Mixed-White/Black",

```

```
}
ethnicity_map = {
    "-50.212": "Asian",
    "-110.702": "Black",
    "190.725": "Mixed-Black/Asian",
    "12.600": "Mixed-White/Asian",
    "-22.166": "Mixed-White/Black",
    "11.440": "Other",
    "-31.685": "White"
}

#aplicando os mappings e salvando a nova tabela
df = spark.table("mvp.silver.drug_consumption")

df = apply_mapping(df, "Age", age_map)
df = apply_mapping(df, "Gender", gender_map)
df = apply_mapping(df, "Education", education_map)
df = apply_mapping(df, "Country", country_map)
df = apply_mapping(df, "Ethnicity", ethnicity_map)

df.write.mode("overwrite").saveAsTable("drug_consumption")
```

Hide performance (1) [View all in query history](#)

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
L70 > df.write.mode("..."	Dec 07, 2025, 09:17 PM	1/1 completed	2 s 729 ms	1,885	26.41 KB	25.42 KB

> df: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

1 minute ago (1s) 22

```
%sql
SELECT *
FROM drug_consumption
LIMIT 10
```

See performance (1) [Optimize](#)

> _sqldf: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

	ID	Age	Gender	Education	Country	Ethnicity	Alcohol	Amphet	Amyl
1	1	35-44	Female	Professional certificate/diplo...	UK	Mixed-White/Asi...	CL5	CL2	CL0
2	2	25-34	Male	Doctorate degree	UK	White	CL5	CL2	CL2
3	3	35-44	Male	Professional certificate/diplo...	UK	White	CL6	CL0	CL0
4	4	18-24	Female	Masters degree	UK	White	CL4	CL0	CL0
5	5	35-44	Female	Doctorate degree	UK	White	CL4	CL1	CL1
6	6	65+	Female	Left school at 18	Canada	White	CL2	CL0	CL0
7	7	45-54	Male	Masters degree	USA	White	CL6	CL0	CL0
8	8	35-44	Male	Left school at 16	UK	White	CL5	CL0	CL0

As colunas de drogas utilizam os mesmos valores, então farei o mapping e aplicarei em todas elas.

1 minute ago (7)

27

```

spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.ID IS 'Number of record in original database. Cannot be related to participant. It can be used for reference only'""")
spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Age IS 'Age of participant and has one of the values: -95.197: 18-24 / -7.854: 25-34 / 49.788: 35-44 / 189.449: 45-54 / 182.213: 55-64 / 259.171: 65+""")
spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Gender IS 'Gender of participant: 48.249: Female / -48.249: Male'""")
spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Education IS 'Level of education of participant and has one of the values: -243.591: Left school before 16 years / -173.798: Left school at 16 years / -143.719: Left school at 17 years / -122.751: Left school at 18 years / -61.113: Some college or university, no certificate or degree / -5.921: Professional certificate or diploma / 45.468: University degree / 116.365: Masters degree / 198.437: Doctorate degree'""")
spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Country IS 'Country of current residence of participant and has one of the values: -9.765: Australia / 24.923: Canada / -46.841: New Zealand / -28.519: Other / 21.128: Republic of Ireland / 96.882: UK / -57.609: USA'""")
spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Ethnicity IS 'Ethnicity of participant and has one of the values: -50.212: Asian / -118.702: Black / 190.725: Mixed-Black/Asian / 12.680: Mixed-White/Asian / -22.166: Mixed-White/Black / 11.440: Other / -31.685: White'""")

```

Hide performance (6)

View all in query history

Statement	Started At	Duration	Rows read	Bytes read	Bytes written
> spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Ethnicity IS 'Ethnicity of participant and has one of the values: -50.212: Asian / -118.702: Black / 190.725: Mixed-Black/Asian / 12.680: Mixed-White/Asian / -22.166: Mixed-White/Black / 11.440: Other / -31.685: White'""")	Dec 07, 2025, 09:46 PM	1 s 33 ms	0	0 B	0 B
> spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Country IS 'Country of current residence of participant and has one of the values: -9.765: Australia / 24.923: Canada / -46.841: New Zealand / -28.519: Other / 21.128: Republic of Ireland / 96.882: UK / -57.609: USA'""")	Dec 07, 2025, 09:46 PM	1 s 18 ms	0	0 B	0 B
> spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Education IS 'Level of education of participant and has one of the values: -243.591: Left school before 16 years / -173.798: Left school at 16 years / -143.719: Left school at 17 years / -122.751: Left school at 18 years / -61.113: Some college or university, no certificate or degree / -5.921: Professional certificate or diploma / 45.468: University degree / 116.365: Masters degree / 198.437: Doctorate degree'""")	Dec 07, 2025, 09:46 PM	1 s 14 ms	0	0 B	0 B
> spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Gender IS 'Gender of participant: 48.249: Female / -48.249: Male'""")	Dec 07, 2025, 09:46 PM	1 s 64 ms	0	0 B	0 B
> spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.Age IS 'Age of participant and has one of the values: -95.197: 18-24 / -7.854: 25-34 / 49.788: 35-44 / 189.449: 45-54 / 182.213: 55-64 / 259.171: 65+""")	Dec 07, 2025, 09:46 PM	1 s 36 ms	0	0 B	0 B
> spark.sql("""COMMENT ON COLUMN mvp.silver.drug_consumption.ID IS 'Number of record in original database. Cannot be related to participant. It can be used for reference only'""")	Dec 07, 2025, 09:46 PM	1 s 744 ms	5	0 B	0 B

DataFrame[]

2.4.4. Quarta tratativa - busca e, caso necessário, limpeza de valores NULL ou Unknown ou vazio

Farei uma busca por todos esses valores inválidos, agrupados nessas categorias de NULL, Unknown ou vazio. Ao final desse código, teremos uma tabela indicando a quantidade encontrada de cada um deles.

Como todas as transformações foram salvas na tabela padrão "drug_consumption", será essa a utilizada nessa busca. A tabela silver continuará como tabela base, somente com o primeiro filtro e com os nomes de colunas corretos.

1 minute ago (2s)

29

Python

```
from pyspark.sql.functions import col, trim, sum as spark_sum
from pyspark.sql import Row

df = spark.table("drug_consumption")

#Monta as agregações (wide): null, Unknown, \N, blank
agg_exprs = []

for c in df.columns:
    null_expr = spark_sum(col(c).isNull().cast("int")).alias(f"{c}_null_count")
    unknown_expr = spark_sum((col(c) == "Unknown").cast("int")).alias(f"{c}_unknown_count")
    backslashN_expr = spark_sum((col(c) == "\\N").cast("int")).alias(f"{c}_backslashN_count")
    blank_expr = spark_sum((trim(col(c)) == "").cast("int")).alias(f"{c}_blank_count")

    agg_exprs.extend([null_expr, unknown_expr, backslashN_expr, blank_expr])

df_checks_wide = df.agg(*agg_exprs)

#Converte o resultado wide (uma linha) em uma lista de linhas "long"
row = df_checks_wide.first()

data = []
for c in df.columns:
    null_count = row[f"{c}_null_count"]
    unknown_count = row[f"{c}_unknown_count"]
    backslashN_count = row[f"{c}_backslashN_count"]
    blank_count = row[f"{c}_blank_count"]
    invalid_total = null_count + unknown_count + backslashN_count + blank_count

    data.append(
        Row(
            column=c,
            null_count=null_count,
            unknown_count=unknown_count,
            backslashN_count=backslashN_count,
            blank_count=blank_count,
            invalid_total=invalid_total
        )
    )

#Cria o DataFrame longo com uma linha por coluna
df_checks_long = spark.createDataFrame(data)

#Ordena pela pior coluna (mais valores inválidos) e mostra tudo
df_checks_long.orderBy(col("invalid_total").desc()).show(1000, False)
```

Hide performance (2)

View all in query history

	Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
L45	> df_checks_long.orderBy(col("inva...	Dec 07, 2025, 10:15 PM	1/1 completed	285 ms	0	0 B	0 B
L20	> row = df_checks_wide.first()	Dec 07, 2025, 10:15 PM	1/1 completed	601 ms	1.885	22.25 KB	0 B

> df: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

> df_checks_long: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

> df_checks_wide: pyspark.sql.connect.dataframe.DataFrame = [ID_null_count: long, ID_unknown_count: long ... 98 more fields]

column	null_count	unknown_count	backslashN_count	blank_count	invalid_total
ID	0	0	0	0	0
Age	0	0	0	0	0
Gender	0	0	0	0	0
Education	0	0	0	0	0
Country	0	0	0	0	0
Ethnicity	0	0	0	0	0
Alcohol	0	0	0	0	0
Amphet	0	0	0	0	0
Amyl	0	0	0	0	0
Benzos	0	0	0	0	0
Caff	0	0	0	0	0
Cannabis	0	0	0	0	0
Choc	0	0	0	0	0
Coke	0	0	0	0	0
Crack	0	0	0	0	0
Ecstasy	0	0	0	0	0
Heroin	0	0	0	0	0
Ketamine	0	0	0	0	0

```
L45 > df_checks_long.orderBy(col("inva... Dec 07, 2025, 10:15 PM 1/1 completed 285 ms 0 0 B 0 B
L20 > row = df_checks_wide.first() Dec 07, 2025, 10:15 PM 1/1 completed 601 ms 1.885 22.25 KB 0 B

> df: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]
> df_checks_long: pyspark.sql.connect.dataframe.DataFrame = [column: string, null_count: long ... 4 more fields]
> df_checks_wide: pyspark.sql.connect.dataframe.DataFrame = [ID_null_count: long, ID_unknown_count: long ... 98 more fields]

|Alcohol|0|0|0|0|0|
|Amphet|0|0|0|0|0|
|Amyl|0|0|0|0|0|
|Benzos|0|0|0|0|0|
|Caff|0|0|0|0|0|
|Cannabis|0|0|0|0|0|
|Choc|0|0|0|0|0|
|Coke|0|0|0|0|0|
|Crack|0|0|0|0|0|
|Ecstasy|0|0|0|0|0|
|Heroin|0|0|0|0|0|
|Ketamine|0|0|0|0|0|
|LegalH|0|0|0|0|0|
|LSD|0|0|0|0|0|
|Methadone|0|0|0|0|0|
|Mushrooms|0|0|0|0|0|
|Nicotine|0|0|0|0|0|
|Semer|0|0|0|0|0|
|VSA|0|0|0|0|0|
```

Com isso, vemos que não existem dados inválidos nem nulos que pudessem atrapalhar as análises. Então seguiremos para a etapa Gold.

2.5. Etapa Gold

Aqui aplicarei mais um filtro nas colunas de drogas, para deixar somente Cannabis, Cocaína e Anfetamina (conforme explicado no Objetivo do trabalho). Escolhi não criar esse filtro antes para que as outras drogas ainda estejam mais facilmente disponíveis para outros tipos de análise, além das propostas neste trabalho.

Também criarei uma nova coluna, chamada "Usuário" do tipo booleana, para ajudar nas análises. Aqui, os valores "Never Used", "Used over a Decade Ago" e "Used in Last Decade" serão considerados como "Não Usuário". Os outros valores serão considerados como "Usuários".

Considereei a criação dessa coluna na etapa silver, antes do filtro final, mas eu teria que criar uma coluna de usuário para cada droga ou uma coluna genérica que considerasse o uso em pelo menos uma delas. Concluí que ambas as opções poderiam atrapalhar a etapa de análise e achei melhor criar agora somente.

11:29 PM (4s)32

#como a tabela final tratada na silver é a drug_consumption, criei a gold como cópia dela
df_silver = spark.table("drug_consumption")
df_silver.write.mode("overwrite").option("overwriteSchema", "true").saveAsTable("mvp.gold.drug_consumption")

> See performance (1)Optimize

df_silver: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

11:31 PM (1s)33

spark.sql("USE CATALOG mvp")
spark.sql("USE SCHEMA gold")

> See performance (2)

DataFrame[]

11:38 PM (2s)34

%sql
SELECT *
FROM mvp.gold.drug_consumption
LIMIT 10

> See performance (1)Optimize

_sqldf: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

Table +

	ID	Age	Gender	Education	Country	Ethnicity	Alcohol	Amphet	Amyl	Benzos	Ca
1	1	49.788	48.246	-5.921	96.082	12.600	CL5	CL2	CL0	CL2	CL6
2	2	-7.854	-48.246	198.437	96.082	-31.685	CL5	CL2	CL2	CL0	CL6
3	3	49.788	-48.246	-5.921	96.082	-31.685	CL6	CL0	CL0	CL0	CL6
4	4	-95.197	48.246	116.365	96.082	-31.685	CL4	CL0	CL0	CL3	CL5
5	5	49.788	48.246	198.437	96.082	-31.685	CL4	CL1	CL1	CL0	CL6
6	6	259.171	48.246	-122.751	24.923	-31.685	CL2	CL0	CL0	CL0	CL6
7	7	109.449	-48.246	116.365	-57.009	-31.685	CL6	CL0	CL0	CL0	CL6
8	8	49.788	-48.246	-173.790	96.082	-31.685	CL5	CL0	CL0	CL0	CL6
9	9	49.788	48.246	-5.921	24.923	-31.685	CL4	CL0	CL0	CL0	CL6
10	10	49.788	48.246	-5.921	24.923	-31.685	CL4	CL0	CL0	CL0	CL6

10 rows | 1.89s runtime

Refreshed 19 minutes ago

This result is stored as _sqldf and can be used in other Python and SQL cells.

Nessa etapa, percebi que algo de errado aconteceu com a tabela refinada. Descobri que ela acabou sendo salva no catálogo chamado "workspace" e não no "mvp". No catálogo "mvp", no schema "silver", a drug_consumption está com os dados base após a primeira tratativa, que foi o nome das colunas.

Então, como eu quero preservar essa tabela base da silver, vou copiar a refinada criando uma nova tabela na silver chamada "drug_consumption_refined" para que essa seja a utilizada na etapa gold.

2 minutes ago (4s)36

```
df_refined = spark.table("workspace.default.drug_consumption")
df_refined.write.mode("overwrite").option("overwriteSchema", "true").saveAsTable("mvp.silver.drug_consumption_refined")
```

See performance (1)Optimize

df_refined: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

1 minute ago (2s)37

```
%sql
SELECT *
FROM mvp.silver.drug_consumption_refined
LIMIT 10
```

See performance (1)Optimize

_sqldf: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

Table +

🔍🏠📄🗑️

	ID	Age	Gender	Education	Country	Ethnicity	Alcohol	Amphet	Amyl
1	1	35-44	Female	Professional certificate/diplo...	UK	Mixed-White/Asi...	Used in last week	Used in last decade	Never used
2	2	25-34	Male	Doctorate degree	UK	White	Used in last week	Used in last decade	Used in last decade
3	3	35-44	Male	Professional certificate/diplo...	UK	White	Used in last day	Never used	Never used
4	4	18-24	Female	Masters degree	UK	White	Used in last month	Never used	Never used
5	5	35-44	Female	Doctorate degree	UK	White	Used in last month	Used over a decade a...	Used over a decade a...
6	6	65+	Female	Left school at 18	Canada	White	Used in last deca...	Never used	Never used
7	7	45-54	Male	Masters degree	USA	White	Used in last day	Never used	Never used
8	8	35-44	Male	Left school at 16	UK	White	Used in last week	Never used	Never used
9	9	35-44	Female	Professional certificate/diplo...	Canada	White	Used in last month	Never used	Never used
10	10	35-44	Female	Professional certificate/diplo...	UK	White	Used in last month	Never used	Never used

10 rows | 1.50s runtime

Refreshed 1 minute ago

This result is stored as _sqldf and can be used in other Python and SQL cells.

Agora temos a tabela refinada na silver. Vou criar a gold a partir dessa.

Just now (3s)39

```
df_silver_refined = spark.table("mvp.silver.drug_consumption_refined")
df_silver_refined.write.mode("overwrite").option("overwriteSchema", "true").saveAsTable("mvp.gold.drug_consumption")
```

See performance (1)Optimize

df_silver_refined: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

Just now (1s)40

```
%sql
SELECT *
FROM mvp.gold.drug_consumption
LIMIT 10
```

See performance (1)Optimize

_sqldf: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

Table +

🔍🏠📄🗑️

	ID	Age	Gender	Education	Country	Ethnicity	Alcohol	Amphet	Amyl
1	1	35-44	Female	Professional certificate/diplo...	UK	Mixed-White/Asi...	Used in last week	Used in last decade	Never used
2	2	25-34	Male	Doctorate degree	UK	White	Used in last week	Used in last decade	Used in last decade
3	3	35-44	Male	Professional certificate/diplo...	UK	White	Used in last day	Never used	Never used
4	4	18-24	Female	Masters degree	UK	White	Used in last month	Never used	Never used
5	5	35-44	Female	Doctorate degree	UK	White	Used in last month	Used over a decade a...	Used over a decade a...
6	6	65+	Female	Left school at 18	Canada	White	Used in last deca...	Never used	Never used
7	7	45-54	Male	Masters degree	USA	White	Used in last day	Never used	Never used
8	8	35-44	Male	Left school at 16	UK	White	Used in last week	Never used	Never used
9	9	35-44	Female	Professional certificate/diplo...	Canada	White	Used in last month	Never used	Never used
10	10	35-44	Female	Professional certificate/diplo...	UK	White	Used in last month	Never used	Never used

10 rows | 1.19s runtime

Refreshed now

This result is stored as _sqldf and can be used in other Python and SQL cells.

Agora sim posso seguir com as últimas tratativas na gold.

Aplicando o filtro para termos somente as colunas de drogas Cannabis, Cocaína e Anfetamina.

42

Python

```
df = spark.table("mvp.gold.drug_consumption")

df_filtered = df.select(
    "Age", "Gender", "Education", "Country", "Ethnicity", "Cannabis", "Coke", "Amphet"
)

df_filtered.write.mode("overwrite").option("overwriteSchema", "true").saveAsTable("mvp.gold.drug_consumption_analytics")
```

Hide performance (1)

View all in query history

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
> df_filtered.write.mode("overwrite")...	Dec 08, 2025, 12:05 AM	1/1 completed	3 s 89 ms	1.885	27.46 KB	8.16 KB

> df: pyspark.sql.connect.dataframe.DataFrame = [ID: string, Age: string ... 23 more fields]

> df_filtered: pyspark.sql.connect.dataframe.DataFrame = [Age: string, Gender: string ... 6 more fields]

43

Just now (1s)

```
%sql
SELECT *
FROM mvp.gold.drug_consumption_analytics
LIMIT 10
```

See performance (1)

Optimize

> _sqldf: pyspark.sql.connect.dataframe.DataFrame = [Age: string, Gender: string ... 6 more fields]

Table

+

🔍

🏠

📄

	Age	Gender	Education	Country	Ethnicity	Cannabis	Coke	Amphet
1	35-44	Female	Professional certificate/diplo...	UK	Mixed-White/Asi...	Never used	Never used	Used in last decade
2	25-34	Male	Doctorate degree	UK	White	Used in last month	Used in last year	Used in last decade
3	35-44	Male	Professional certificate/diplo...	UK	White	Used in last year	Never used	Never used
4	18-24	Female	Masters degree	UK	White	Used in last decade	Used in last deca...	Never used
5	35-44	Female	Doctorate degree	UK	White	Used in last year	Never used	Used over a decade a...
6	65+	Female	Left school at 18	Canada	White	Never used	Never used	Never used
7	45-54	Male	Masters degree	USA	White	Used over a decade a...	Never used	Never used
8	35-44	Male	Left school at 16	UK	White	Never used	Never used	Never used
9	35-44	Female	Professional certificate/diplo...	Canada	White	Never used	Never used	Never used
10	55-64	Male	Masters degree	UK	White	Used over a decade a...	Never used	Used over a decade a...

📄

10 rows

1.38s runtime

Refreshed now

📘

This result is stored as `_sqldf` and can be used in other Python and SQL cells.

Agora vou criar uma nova coluna, chamada "Usuário" do tipo booleana, para ajudar nas análises. Aqui, os valores "Never Used", "Used over a Decade Ago" e "Used in Last Decade" serão considerados como "Não Usuário" (false). Os outros valores serão considerados como "Usuários" (true).

Será uma coluna única que considerará como usuário alguém que usou pelo menos uma das 3 drogas listadas nessa etapa.

1 minute ago (3s)45

```
from pyspark.sql.functions import col

df = spark.table("mvp.gold.drug_consumption_analytics")

# valores que representam NÃO USUÁRIO
non_user_values = [
    "Never used",
    "Used over a decade ago",
    "Used in last decade"
]

# criar coluna geral: usuario se usar qualquer uma das 3 drogas
df = df.withColumn(
    "Usuario",
    ~col("Cannabis").isin(non_user_values) |
    ~col("Coke").isin(non_user_values) |
    ~col("Amphet").isin(non_user_values)
)

df.write.mode("overwrite").option("overwriteSchema", "true").saveAsTable("mvp.gold.drug_consumption_analytics")
```

> [View performance \(1\)](#)

df: pyspark.sql.connect.dataframe.DataFrame = [Age: string, Gender: string ... 7 more fields]

1 minute ago (1s)46

```
%sql
SELECT *
FROM mvp.gold.drug_consumption_analytics
LIMIT 10
```

> [View performance \(1\)](#)

_sqldf: pyspark.sql.connect.dataframe.DataFrame = [Age: string, Gender: string ... 7 more fields]

Table +

🔍 🔍 📄 📄

	🔍 Age	🔍 Gender	🔍 Education	🔍 Country	🔍 Ethnicity	🔍 Cannabis	🔍 Coke	🔍 Amphet	🔍 Usuario
1	35-44	Female	Professional certificate/diplo...	UK	Mixed-White/Asi...	Never used	Never used	Used in last decade	false
2	25-34	Male	Doctorate degree	UK	White	Used in last month	Used in last year	Used in last decade	true
3	35-44	Male	Professional certificate/diplo...	UK	White	Used in last year	Never used	Never used	true
4	18-24	Female	Masters degree	UK	White	Used in last decade	Used in last deca...	Never used	false
5	35-44	Female	Doctorate degree	UK	White	Used in last year	Never used	Used over a decade a...	true
6	65+	Female	Left school at 18	Canada	White	Never used	Never used	Never used	false
7	45-54	Male	Masters degree	USA	White	Used over a decade a...	Never used	Never used	false
8	35-44	Male	Left school at 16	UK	White	Never used	Never used	Never used	false
9	35-44	Female	Professional certificate/diplo...	Canada	White	Never used	Never used	Never used	false
10	55-64	Male	Masters degree	UK	White	Used over a decade a...	Never used	Used over a decade a...	false

📄 10 rows | 1.25s runtime

Refreshed 1 minute ago

Pronto, agora temos a tabela que será utilizada como referência para responder às perguntas propostas no objetivo do trabalho.

3. ANÁLISES

Agora, iniciaremos as análises desse dataset, tendo como base a tabela `mvp.gold.drug_consumption_analytics`, para responder as seguintes perguntas:

- Qual o perfil dos maiores usuários de drogas? Idade, Gênero e Escolaridade seguem algum padrão nesses casos?

Para facilitar o cruzamento de dados em análise e para não "engessar" a atualização de novos inputs, ao invés de criar uma tabela-fato preferi criar uma view-fato, a qual será a minha base de análise já considerando os usuários e com todos os atributos que preciso. A

partir dela, criarei as views dimensionais para as análises específicas e os cruzamentos de dados.

✓ Dec 08, 2025 (1s)
49
Python

```
spark.sql("USE CATALOG mvp")
spark.sql("USE SCHEMA gold")
```

Hide performance (2)
[View all in query history](#)

	Statement	Started At	Duration	Rows read	Bytes read	Bytes written
L2	> spark.sql("USE SCHEMA gold")	Dec 08, 2025, 10:25 PM	109 ms	0	0 B	0 B
L1	> spark.sql("USE CATALOG mvp")	Dec 08, 2025, 10:25 PM	98 ms	0	0 B	0 B

DataFrame[]

✓ 10:50 PM (1s)
51
[See performance \(1\)](#) Optimize

```
%sql
CREATE OR REPLACE VIEW mvp.gold.v_drug_usage_fact AS
SELECT *
-- usuario de cada droga
CASE
WHEN Cannabis IN ('Used in last year','Used in last month','Used in last week','Used in last day')
THEN TRUE ELSE FALSE
END AS Usuario_Cannabis,
CASE
WHEN Coke IN ('Used in last year','Used in last month','Used in last week','Used in last day')
THEN TRUE ELSE FALSE
END AS Usuario_Coke,
CASE
WHEN Amphet IN ('Used in last year','Used in last month','Used in last week','Used in last day')
THEN TRUE ELSE FALSE
END AS Usuario_Amphet
FROM mvp.gold.drug_consumption_analytics;
```

OK
[See performance \(1\)](#) Optimize

✓ 10:52 PM (Ds)
52
[See performance \(1\)](#) Optimize

```
%sql
select * from mvp.gold.v_drug_usage_fact;
```

%sqldf: pyspark.sql.connect.dataframe.DataFrame = (Age: string, Gender: string ... 10 more fields)
[See performance \(1\)](#) Optimize

Table	+ Age	Gender	Education	Country	Ethnicity	Cannabis	Coke	Amphet	Usuario	Usuario_Cannabis	Usuario_Coke	Usuario_Amphet
1	35-44	Female	Professional certificate/diploma	UK	Mixed_White/Asi...	Never used	Never used	Used in last decade	false	false	false	false
2	25-34	Male	Doctorate degree	UK	White	Used in last month	Used in last year	Used in last decade	true	true	true	false
3	35-44	Male	Professional certificate/diploma	UK	White	Used in last year	Never used	Never used	true	true	false	false
4	18-24	Female	Masters degree	UK	White	Used in last decade	Used in last decade	Never used	false	false	false	false
5	35-44	Female	Doctorate degree	UK	White	Used in last year	Never used	Used over a decade a...	true	true	false	false
6	65+	Female	Left school at 18	Canada	White	Never used	Never used	Never used	false	false	false	false
7	45-54	Male	Masters degree	USA	White	Used over a decade a...	Never used	Never used	false	false	false	false
8	35-44	Male	Left school at 16	UK	White	Never used	Never used	Never used	false	false	false	false
9	35-44	Female	Professional certificate/diploma	Canada	White	Never used	Never used	Never used	false	false	false	false
10	55-64	Male	Masters degree	UK	White	Used over a decade a...	Never used	Used over a decade a...	false	false	false	false
11	25-34	Female	University degree	UK	White	Used in last decade	Used in last decade	Never used	false	false	false	false
12	45-54	Male	Some college/university, no degr...	Other	White	Used in last month	Used in last decade	Used over a decade a...	true	true	false	false
13	55-64	Female	University degree	UK	White	Used in last year	Used over a decade a...	Used over a decade a...	true	true	false	false
14	55-64	Female	Professional certificate/diploma	Canada	White	Never used	Never used	Never used	false	false	false	false
15	55-64	Female	Professional certificate/diploma	UK	White	Never used	Never used	Never used	false	false	false	false

↓ 1,885 rows | 1.55s runtime
Refreshed 23 minutes ago

Agora criarei as views dimensionais para cada classe que quero analisar: idade, gênero e escolaridade.

10:59 PM (1h)54

```
%sql
CREATE OR REPLACE VIEW mvp.gold.v_usage_by_age AS
SELECT
  Age,
  COUNT(*) AS total_pessoas,
  SUM(CASE WHEN Usuario THEN 1 ELSE 0 END) AS usuarios_qualquer_droga,
  ROUND(100.0 * SUM(CASE WHEN Usuario THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_qualquer_droga,
  SUM(CASE WHEN Usuario_Cannabis THEN 1 ELSE 0 END) AS usuarios_cannabis,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Cannabis THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_cannabis,
  SUM(CASE WHEN Usuario_Coke THEN 1 ELSE 0 END) AS usuarios_coke,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Coke THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_coke,
  SUM(CASE WHEN Usuario_Amphet THEN 1 ELSE 0 END) AS usuarios_amphet,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Amphet THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_amphet
FROM mvp.gold.v_drug_usage_fact
GROUP BY Age
ORDER BY Age;
```

See performance (1)Optimize

OK

11:01 PM (2h)55

```
%sql
select * from mvp.gold.v_usage_by_age;
```

Hide performance (1)View all in query history

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
> select * from mvp.gold.v_usage_by_age	Dec 08, 2025, 11:01 PM	1/1 completed	791 ms	1,885	8,57 KB	0 B

> _sqldf: pyspark.sql.connect.dataframe.DataFrame = (Age: string, total_pessoas: long ... 8 more fields)

Age	total_pessoas	usuarios_qualquer_droga	pct_usuarios_qualquer_droga	usuarios_cannabis	pct_usuarios_cannabis	usuarios_coke	pct_usuarios_coke	usuarios_amphet	pct_usuarios_amphet
18-24	643	550	85.5	536	83.4	226	35.1	259	40.3
25-34	481	260	54.1	238	49.5	122	25.4	107	22.2
35-44	356	136	38.2	123	34.6	45	12.6	36	10.1
45-54	294	85	28.9	75	25.5	20	6.8	31	10.5
55-64	93	28	30.1	26	28.0	4	4.3	3	3.2
65+	18	1	5.6	1	5.6	0	0.0	0	0.0

6 rows | 1.74s runtime

Refreshed 15 minutes ago

This result is stored as `_sqldf` and can be used in other Python and SQL cells.

Aqui temos a porcentagem de usuários recentes, que usou minimamente no último ano, para cada droga e organizado por idade. Vemos que a droga mais utilizada dentre as 3 é a maconha em todas as faixas etárias, chegando a 83,4% entre pessoas de 18-24 anos, sendo a única usada em todas as idades. Já a anfetamina supera a cocaína em 2 faixas: 18-24 (os mais jovens) e 45-54 (os de meia idade), mas a quantidade de usuários de ambas é bem próxima.

Temos também a quantidade de usuários de pelo menos uma das 3 drogas (usuario_qualquer_droga). Quase todos os jovens (643) podem ser considerados usuários (550). Podemos observar que a quantidade de usuários vai diminuindo conforme a faixa etária vai aumentando, caindo mais de 50% a partir dos 45 anos.

11:02 PM (16) 57

```
Xsql
CREATE OR REPLACE VIEW mvp.gold.v_usage_by_gender AS
SELECT
  Gender,
  COUNT(*) AS total_pessoas,
  SUM(CASE WHEN Usuario THEN 1 ELSE 0 END) AS usuarios_qualquer_droga,
  ROUND(100.0 * SUM(CASE WHEN Usuario THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_qualquer_droga,
  SUM(CASE WHEN Usuario_Cannabis THEN 1 ELSE 0 END) AS usuarios_cannabis,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Cannabis THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_cannabis,
  SUM(CASE WHEN Usuario_Coke THEN 1 ELSE 0 END) AS usuarios_coke,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Coke THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_coke,
  SUM(CASE WHEN Usuario_Amphet THEN 1 ELSE 0 END) AS usuarios_amphet,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Amphet THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_amphet
FROM mvp.gold.v_drug_usage_fact
GROUP BY Gender
ORDER BY Gender;
```

> See performance (1) [Optimize](#)

OK

11:03 PM (16) 58

```
Xsql
select * from mvp.gold.v_usage_by_gender;
```

> Hide performance (1) [View all in query history](#)

Statement	Started At	Duration	Rows read	Bytes read	Bytes written
> select * from mvp.gold.v_usage_by_gender	Dec 08, 2025, 11:03 PM	601 ms	1,885	8.57 KB	0 B

Table	Gender	total_pessoas	usuarios_qualquer_droga	pct_usuarios_qualquer_droga	usuarios_cannabis	pct_usuarios_cannabis	usuarios_coke	pct_usuarios_coke	usuarios_amphet	pct_usuarios_amphet
1	Female	942	395	41.9	364	38.6	146	15.5	137	14.5
2	Male	943	665	70.5	635	67.3	271	28.7	299	31.7

2 rows | 1.43s runtime

Refreshed 14 minutes ago

This result is stored as [sqldf](#) and can be used in other Python and SQL cells.

Aqui temos uma visualização por gênero e vemos que tem-se igual quantidade total de pessoas de ambos os sexos. Fica claro que a quantidade de homens usuários é quase o dobro da quantidade de mulheres usuárias, tanto quando generalizamos as drogas quanto em cada uma delas.

A maconha segue sendo a mais consumida, mas nas outras duas temos uma inversão. Mulheres consomem mais cocaína e homens consomem mais anfetamina.

11:03 PM (16) 60

```
Xsql
CREATE OR REPLACE VIEW mvp.gold.v_usage_by_education AS
SELECT
  Education,
  COUNT(*) AS total_pessoas,
  SUM(CASE WHEN Usuario THEN 1 ELSE 0 END) AS usuarios_qualquer_droga,
  ROUND(100.0 * SUM(CASE WHEN Usuario THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_qualquer_droga,
  SUM(CASE WHEN Usuario_Cannabis THEN 1 ELSE 0 END) AS usuarios_cannabis,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Cannabis THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_cannabis,
  SUM(CASE WHEN Usuario_Coke THEN 1 ELSE 0 END) AS usuarios_coke,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Coke THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_coke,
  SUM(CASE WHEN Usuario_Amphet THEN 1 ELSE 0 END) AS usuarios_amphet,
  ROUND(100.0 * SUM(CASE WHEN Usuario_Amphet THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_usuarios_amphet
FROM mvp.gold.v_drug_usage_fact
GROUP BY Education
ORDER BY Education;
```

> See performance (1) [Optimize](#)

OK

11:04 PM (16) 61

```
Xsql
select * from mvp.gold.v_usage_by_education;
```

> Hide performance (1) [View all in query history](#)

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
> select * from mvp.gold.v_usage_by_education	Dec 08, 2025, 11:04 PM	1/1 completed	512 ms	1,885	8.57 KB	0 B

Table	Education	total_pessoas	usuarios_qualquer_droga	pct_usuarios_qualquer_droga	usuarios_cannabis	pct_usuarios_cannabis	usuarios_coke	pct_usuarios_coke	usuarios_amphet	pct_usuarios_amphet
1	Doctorate degree	89	36	40.4	31	34.8	15	16.9	11	12.4
2	Left school at 16	99	48	48.5	44	44.4	15	15.2	15	15.2
3	Left school at 17	30	21	70.0	20	66.7	9	30.0	9	30.0
4	Left school at 18	100	70	70.0	69	69.0	24	24.0	36	36.0
5	Left school before 16	28	19	67.9	18	64.3	5	17.9	6	21.4
6	Masters degree	283	96	33.9	87	30.7	40	14.1	30	10.6
7	Professional certificate/diploma	270	126	46.7	118	43.7	53	19.6	42	15.6
8	Some college/university, no degr...	506	425	84.0	408	80.6	169	33.4	207	40.9
9	University degree	480	219	45.6	204	42.5	87	18.1	80	16.7

9 rows | 1.31s runtime


Refreshed 16 minutes ago

Agora em relação ao grau de escolaridade, vemos que a maior parte dos usuários está no grupo de pessoas com certo grau de escolaridade, que são as pessoas com diploma ou que já frequentaram ou frequentam universidades/faculdades sem concluí-las. Curiosamente, os menores números estão nos extremos, entre pessoas com baixo grau de escolaridade e pessoas com os mais altos graus de escolaridade. Porém, se olharmos para a quantidade de cadastros nessas faixas e a quantidade de usuários, vemos que as porcentagens de usuários são consideráveis.

Desses grupos com quantidades mais expressivas, vemos que os "não formados" são quase em sua totalidade usuários (84%) e que os formados em nível superior somente tem porcentagens praticamente iguais (46,7% e 45,6%). Ainda que no total os formados em universidades tenham porcentagem ligeiramente menor, quando olhamos para cada droga vemos que existem quase o dobro de usuários nesse grupo, indicando que a quantidade de pessoas cadastradas nessa categoria acabou influenciando a porcentagem geral.

Com essas views criadas, podemos fazer algumas consultas para concluir o questionamento sobre o perfil dos maiores usuários e se existe um padrão nas características.

Primeiro, veremos as 10 combinações mais frequentes de usuários.



```
%sql
SELECT Age, Gender, Education,
COUNT(*) AS total_usuarios,
ROUND(
100.0 * COUNT(*) /
(SELECT COUNT(*) FROM mvp.gold.v_drug_usage_fact WHERE Usuario = TRUE),
1
) AS pct_dos_usuarios
FROM mvp.gold.v_drug_usage_fact
WHERE Usuario = TRUE
GROUP BY Age, Gender, Education
ORDER BY total_usuarios DESC
LIMIT 10;
```

	Age	Gender	Education	total_usuarios	pct_dos_usuarios
1	18-24	Male	Some college/university, no degr...	227	21.4
2	18-24	Female	Some college/university, no degr...	84	7.9
3	25-34	Male	Some college/university, no degr...	53	5.0
4	18-24	Male	University degree	47	4.4
5	25-34	Female	University degree	44	4.2
6	18-24	Male	Left school at 18	42	4.0
7	18-24	Female	University degree	40	3.8
8	25-34	Female	Masters degree	36	3.4
9	18-24	Male	Professional certificate/diploma	34	3.2
10	25-34	Male	University degree	27	2.5

Confirmando o que vimos nas views, a maior quantidade de usuários é formada por homens jovens que não concluíram o ensino superior (aqui fica a dúvida sobre esse dataset, se essa categoria de educação pode significar que ainda estão cursando). Essa quantidade é quase o triplo do segundo grupo de mesmas características, porém formado por mulheres.

Podemos perceber que as características de gênero e escolaridade variam bastante, enquanto que a faixa etária permanece nos jovens de 18 a 34 anos, mostrando que há um ponto em comum entre esses usuários.

Por fim, faremos uma consulta para verificar os perfis mais frequentes considerando cada uma das drogas. Assim, veremos quais drogas os maiores usuários utilizam.

```
3 minutos ago (3)

Ksql
WITH exploded AS (
  SELECT Age, Gender, Education,
    -- "desempilha" as 3 drogas em linhas:
    STACK(
      3,
      'Cannabis', Usuario_Cannabis,
      'Coke',      Usuario_Coke,
      'Amphet',   Usuario_Amphet
    ) AS (droga, is_user)
  FROM mp.gold.v.drug_usage_fact
),
agg AS (
  SELECT droga, Age, Gender, Education,
    COUNT(*) AS total_usuarios_droga,
    -- % dentro do universo daquela droga
    ROUND(
      100.0 * COUNT(*) /
      SUM(COUNT(*)) OVER (PARTITION BY droga),
      1
    ) AS pct_usuarios_droga
  FROM exploded
  WHERE is_user = TRUE
  GROUP BY droga, Age, Gender, Education
),
ranked AS (
  SELECT droga, Age, Gender, Education, total_usuarios_droga, pct_usuarios_droga,
    ROW_NUMBER() OVER (
      PARTITION BY droga
      ORDER BY total_usuarios_droga DESC
    ) AS rn
  FROM agg
)
SELECT droga, Age, Gender, Education, total_usuarios_droga, pct_usuarios_droga
FROM ranked
WHERE rn <= 5
ORDER BY total_usuarios_droga DESC;
```

View all in query history

Statement	Started At	Tasks	Duration	Rows read	Bytes read	Bytes written
> WITH exploded AS (SELECT Age, Gender, Education, -- "desempilha" as 3 drogas em linhas: STACK(3, 'Cannabis', Usuario_Cannabis, 'Coke',...	Dec 08, 2025, 11:58 PM	2/2 completed	780 ms	1,885	8,57 KB	0 B

psql: pyspark.sql connect dataframe.DataFrame = [droga: string, Age: string ... 4 more fields]

Statement

Started At 08/20/2025, 11:58 PM

Tasks 2/2 completed

Duration 780 ms

Rows read 1,885

Bytes read 8.57 KB

Bytes written 0 B

> WITH exploded AS (SELECT Age, Gender, Education, ... "descombiha" as droga FROM STAGE('Cannabis', 'Userio_Cannabis', 'Coke', ...))

> sqdf: pyspark.sql.connect.dataframe.DataFrame = [droga: string, Age: string ... 4 more fields]

Table

	droga	Age	Gender	Education	total_usuarios_droga	pct_usuarios_droga
1	Cannabis	18-24	Male	Some college/university, no degree	223	22.3
2	Amphet	18-24	Male	Some college/university, no degree	124	28.4
3	Coke	18-24	Male	Some college/university, no degree	94	22.5
4	Cannabis	18-24	Female	Some college/university, no degree	81	8.1
5	Cannabis	18-24	Male	University degree	47	4.7
6	Cannabis	25-34	Male	Some college/university, no degree	47	4.7
7	Cannabis	18-24	Male	Left school at 18	42	4.2
8	Amphet	18-24	Female	Some college/university, no degree	33	7.6
9	Coke	18-24	Female	Some college/university, no degree	30	7.2
10	Amphet	25-34	Male	Some college/university, no degree	28	6.4
11	Amphet	18-24	Male	University degree	26	6.0
12	Coke	25-34	Male	Some college/university, no degree	26	6.2
13	Amphet	18-24	Male	Left school at 18	23	5.3
14	Coke	18-24	Male	University degree	20	4.8
15	Coke	18-24	Female	University degree	19	4.6

15 rows | 1.64s runtime

Refreshed 3 minutes ago

Com isso, temos a confirmação de um perfil predominante para todas as 3 drogas: jovens homens sem formação superior concluída (ou em andamento). Podemos analisar esse perfil como sendo homens no início da vida adulta, querendo viver novas experiências trazidas pela liberdade da idade. Estando com o ensino superior em andamento, estão vivenciando o ambiente das faculdades e universidades, onde acontecem muitas festas. A presença da maconha no topo da lista é facilmente justificável pela facilidade que se tem de obter a droga e até mesmo produzir. Já a anfetamina me remete a ambientes de festas, típicos de universidades e eventos jovens.

Agora vamos para a segunda pergunta:

- Existe correlação entre consumo de Cannabis, Anfetaminas e Cocaína? (co-uso)

Primeiro, vamos ver quantas pessoas usam mais de uma droga ao mesmo tempo e qual o perfil dos co-usuários. Combinarei as colunas de usuários independente do perfil, inicialmente, para termos as quantidades independentes e combinadas. Na segunda consulta, voltaremos com as características e olharemos para o total de usuários independente da droga.

10:54 PM (DB)

71

```
%sql
SELECT
  SUM(CASE WHEN Usuario_Cannabis THEN 1 ELSE 0 END) AS cannabis_users,
  SUM(CASE WHEN Usuario_Coke THEN 1 ELSE 0 END) AS coke_users,
  SUM(CASE WHEN Usuario_Amphet THEN 1 ELSE 0 END) AS amphet_users,

  -- co-uso
  SUM(CASE WHEN Usuario_Cannabis AND Usuario_Coke THEN 1 ELSE 0 END) AS cannabis_coke_co_use,
  SUM(CASE WHEN Usuario_Cannabis AND Usuario_Amphet THEN 1 ELSE 0 END) AS cannabis_amphet_co_use,
  SUM(CASE WHEN Usuario_Coke AND Usuario_Amphet THEN 1 ELSE 0 END) AS coke_amphet_co_use,

  -- co-uso das 3
  SUM(CASE WHEN Usuario_Cannabis AND Usuario_Coke AND Usuario_Amphet THEN 1 ELSE 0 END) AS all_three
FROM mvp.gold.v_drug_usage_fact;
```

See performance (1)

%sqldf: pyspark.sql.connect.dataframe.DataFrame = [cannabis_users: long, coke_users: long ... 5 more fields]

Table

	cannabis_users	coke_users	amphet_users	cannabis_coke_co_use	cannabis_amphet_co_use	coke_amphet_co_use	all_three
1	999	417	436	374	398	246	226

1 row | 36.04s runtime

Refreshed 8 minutes ago

This result is stored as `%sqldf` and can be used in other Python and SQL cells.

2 minutes ago (1)

72

```
%sql
SELECT Age, Gender, Education,
  COUNT(*) AS total_co_users
FROM mvp.gold.v_drug_usage_fact
WHERE
  CAST(Usuario_Cannabis AS INT) + CAST(Usuario_Coke AS INT) + CAST(Usuario_Amphet AS INT) >= 2
GROUP BY Age, Gender, Education
ORDER BY total_co_users DESC
LIMIT 10;
```

See performance (1)

%sqldf: pyspark.sql.connect.dataframe.DataFrame = [Age: string, Gender: string ... 2 more fields]

Table

	Age	Gender	Education	total_co_users
1	18-24	Male	Some college/university, no degr...	144
2	18-24	Female	Some college/university, no degr...	41
3	25-34	Male	Some college/university, no degr...	33
4	18-24	Male	University degree	32
5	18-24	Male	Left school at 18	25
6	18-24	Female	University degree	24
7	25-34	Female	University degree	21
8	18-24	Male	Professional certificate/diploma	18
9	25-34	Female	Masters degree	17
10	25-34	Male	University degree	15

10 rows | 1.49s runtime

Refreshed 2 minutes ago

This result is stored as `%sqldf` and can be used in other Python and SQL cells.

Vemos, mais uma vez, a predominância de homens jovens com ensino superior a concluir. Existe uma diferença de quase 400% entre homens e mulheres, na mesma faixa-etária e mesmo grau de escolaridade.


Em relação ao co-uso, fica bem claro a predominância de usuários de maconha (mais do que o dobro em relação às outras) e também o co-uso dessas drogas. Dos 417 usuários de cocaína, 374 também usam maconha. Dos 436 usuários de anfetamina, 398 também usam maconha. Ou seja, quase todos os usuários das outras duas drogas também usam maconha, o que deve estar relacionado ao fato dela ser a porta de entrada para o mundo das drogas.

A relação entre usuários de cocaína e anfetamina também é bem forte, sendo mais da metade de cada uma co-usuário da outra. Por fim, o co-uso triplo também teve um resultado expressivo, sendo metade dos usuários de cocaína e anfetamina.

Por fim, para responder a terceira pergunta, precisamos considerar tudo o que foi visto até então. Além disso, adicionarei mais dois parâmetros, indicando qual o perfil de usuários ocasionais e qual o perfil de usuários frequentes (viciados).

Lembrando, a terceira pergunta era:


- Como o poder público poderia atuar para reduzir a quantidade de usuários?



The screenshot shows a Databricks SQL query editor with a query to identify occasional users of cannabis, cocaine, and amphetamines. The query filters for users who have used these substances in the last year. The results table displays the top 10 users based on the number of occasional uses, ordered by cannabis use, then cocaine, then amphetamines.

```
%sql
SELECT Age, Gender, Education,
SUM(CASE WHEN Cannabis = 'Used in last year' THEN 1 END) AS uso_ocasional_cannabis,
SUM(CASE WHEN Coke = 'Used in last year' THEN 1 END) AS uso_ocasional_coke,
SUM(CASE WHEN Amphet = 'Used in last year' THEN 1 END) AS uso_ocasional_amphet
FROM mwp.gold.v.drug_usage_fact
GROUP BY Age, Gender, Education
ORDER BY
uso_ocasional_cannabis DESC,
uso_ocasional_coke DESC,
uso_ocasional_amphet DESC
LIMIT 10;
```

Age	Gender	Education	uso_ocasional_cannabis	uso_ocasional_coke	uso_ocasional_amphet
18-24	Male	Some college/university, no degr...	27	55	63
25-34	Female	University degree	16	11	6
18-24	Female	Some college/university, no degr...	13	20	16
25-34	Female	Masters degree	13	7	5
18-24	Female	University degree	10	11	8
18-24	Male	University degree	9	10	10
35-44	Female	University degree	9	3	1
25-34	Male	University degree	7	9	3
35-44	Male	Professional certificate/diploma	7	6	2
25-34	Male	Some college/university, no degr...	6	19	14



The screenshot shows a Databricks SQL query editor with a query to identify frequent users of cannabis, cocaine, and amphetamines. The query filters for users who have used these substances in the last day. The results table displays the top 10 users based on the number of frequent uses, ordered by cannabis use, then cocaine, then amphetamines.

```
%sql
SELECT Age, Gender, Education,
SUM(CASE WHEN Cannabis = 'Used in last day' THEN 1 END) AS uso_frequente_cannabis,
SUM(CASE WHEN Coke = 'Used in last day' THEN 1 END) AS uso_frequente_coke,
SUM(CASE WHEN Amphet = 'Used in last day' THEN 1 END) AS uso_frequente_amphet
FROM mwp.gold.v.drug_usage_fact
GROUP BY Age, Gender, Education
ORDER BY
uso_frequente_cannabis DESC,
uso_frequente_coke DESC,
uso_frequente_amphet DESC
LIMIT 10;
```

Age	Gender	Education	uso_frequente_cannabis	uso_frequente_coke	uso_frequente_amphet
18-24	Male	Some college/university, no degr...	121	5	17
18-24	Female	Some college/university, no degr...	35	1	9
18-24	Male	Left school at 18	25	2	6
25-34	Male	Some college/university, no degr...	22	1	6
18-24	Male	University degree	22	1	4
18-24	Female	University degree	15	2	3
18-24	Male	Professional certificate/diploma	13	1	3
25-34	Female	University degree	12	1	7
25-34	Male	University degree	11	1	7
25-34	Male	Professional certificate/diploma	10	1	3

Olhando o resultado de uso ocasional, vemos o perfil predominante, já definido anteriormente, em primeiro lugar mas com baixo número de usuários de maconha. Aqui, as outras drogas acabam superando.

Também vemos uma presença maior de jovens mulheres com nível superior completo, superando até os homens na faixa-etária de 25-34 anos.

Porém, quando olhamos para o resultado de uso frequente, o cenário já conhecido retorna, com maior presença de homens e alto número de usuários de maconha, confirmando que o uso da maconha tende a se tornar vício enquanto que o uso de cocaína e anfetamina tendem a se relacionar com ambientes de festas e acontecimentos pontuais.

Com isso, fica evidente a necessidade de atuação do poder público entre os jovens nos ambientes de faculdade/universidade. Porém, acredito que tenha uma importância ainda maior as campanhas de prevenção enquanto os jovens ainda não chegaram nesse mundo de liberdade e curtição, sendo necessária a presença em escolas e colégios.

4. CONCLUSÃO

As análises indicam padrões claros e consistentes no consumo de Cannabis, Cocaína e Anfetaminas. A Cannabis se destaca como a droga mais consumida em todas as faixas etárias, sendo a única presente ao longo de todo o ciclo de vida analisado e atingindo seu pico entre jovens de 18 a 24 anos, onde mais de 80% são usuários recentes. Vemos também que o uso de ao menos uma das três drogas diminui progressivamente com o aumento da idade, caindo consideravelmente a partir dos 45 anos, o que reforça uma questão geracional relacionada ao consumo.

A variável gênero apresenta diferenças marcantes: embora o número total de homens e mulheres no dataset seja equivalente, a proporção de homens usuários é quase o dobro da de mulheres, tanto no consumo geral quanto por droga. Ainda assim, há distinções relevantes entre substâncias, com maior consumo de cocaína entre mulheres e maior consumo de anfetaminas entre homens, indicando que fatores sociais e contextuais influenciam o tipo de droga consumida.

Em relação à escolaridade, a maior quantidade de usuários concentra-se entre pessoas que iniciaram, mas não concluíram o ensino superior, onde quase todos são usuários. Os extremos educacionais (menor e maior grau de escolaridade) apresentam menor número absoluto de usuários, mas percentuais ainda relevantes, mostrando que a escolaridade, isoladamente, não elimina o risco. A combinação mais recorrente de características é formada por homens jovens (18–34 anos) com ensino superior incompleto, perfil que aparece de forma dominante em praticamente todas as análises, com diferenças expressivas em relação aos demais grupos.

O estudo do co-uso revela uma correlação muito forte entre as drogas analisadas. A grande maioria dos usuários de cocaína e anfetaminas também consome Cannabis, indicando que esta atua como elemento central e possível porta de entrada para o uso de outras substâncias. Além disso, mais da metade dos usuários de cocaína e anfetaminas consome ambas, e o co-uso triplo apresenta valores elevados, reforçando a existência de um padrão de co-uso.

Por fim, a análise entre uso ocasional e uso frequente traz um ponto relevante: enquanto o uso ocasional apresenta maior diversidade de perfis, com maior participação feminina e pessoas com ensino superior completo, o uso frequente retorna ao padrão

dominante de homens jovens e alto consumo de Cannabis, sugerindo maior potencial de dependência associado a essa substância, enquanto cocaína e anfetaminas aparecem mais vinculadas a contextos pontuais, como eventos sociais e festas.

Diante desses resultados, torna-se evidente que políticas públicas eficazes devem priorizar jovens, especialmente no ambiente educacional, com foco particular em universidades e faculdades. No entanto, os dados também indicam que ações preventivas ainda mais precoces, em escolas e colégios, são fundamentais para reduzir a entrada nesse ciclo de consumo, atuando antes que o contexto de maior autonomia e exposição social se estabeleça.

5. QUALIDADE DOS DADOS

Em relação à qualidade dos dados, acredito que a forma de cadastro das informações através de números "não-lógicos" dificulta bastante o uso dessa database. É importantíssimo o mapeamento desses valores com seus significados para que as análises possam ser executadas de forma correta e objetiva. Porém, o mapeamento na forma que foi feito aqui não ajuda nos casos de carga de novos dados, pois precisam chegar como números para então serem traduzidos. Acredito que um modelo de machine learning possa ser adicionado ao pipeline para tratar os inputs de dados, fazendo a codificação para os números definidos para depois o pipeline normalizar com valores inteligíveis.

Ainda assim, acredito que as informações foram boas e suficientes para diversas análises, tendo oportunidades para muitas outras com os dados que não foram utilizados nesse trabalho.

6. AUTO-AVALIAÇÃO

Ainda que eu trabalhe um pouco com linguagem SQL relacional, em um sistema que roda em cima de uma database com diversas tabelas, views, triggers e queries, recebendo dados de diferentes fontes e formas, eu não conhecia o conceito de Data Warehouse nem Data Lake. Pesquisando e desenvolvendo o presente trabalho, percebi que o sistema da empresa pode ser considerado um Data Lake, já que possui todas as etapas de carga, tratamento e dashboards informativos.

Iniciei o trabalho com certo medo, mas acabei gostando bastante de todo o processo. Aos poucos, os estudos foram saindo da abstração e deixando de parecer o bicho de sete cabeças inicial. A minha maior dificuldade foi iniciar, depois tudo fluiu bem. Infelizmente, por falta de disponibilidade para aprofundamento, não consegui fazer um projeto mais completo e elegante, mas quero continuar com os estudos nessa área e pretendo melhorar futuramente esse trabalho.